

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет об исследовательском проекте
на тему
Изучение задачи регрессии в машинном обучении на примере машинно-обучаемых
межатомных потенциалов

Выполнен студентом:

Группы БПМИ245 _____ Маннанов Булат Рашитович
ФИО студента

Проверен руководителем проекта:

Новиков Иван Сергеевич, к. ф.-м. н.

ФИО, научная степень (если есть)

Доцент

Должность

Факультет компьютерных наук / Департамент больших данных и информационного поиска

Место работы (организация или департамент НИУ ВШЭ)

Москва 2026

Содержание

Аннотация	2
1 Введение	3
2 Постановка задачи и метрики	5
2.1 Метрики качества	5
2.2 Правила интерпретации разбиений	6
3 Обзор литературы и используемые модели	7
3.1 Машинно-обучаемые межатомные потенциалы	7
3.2 МТР как специализированный потенциал	7
3.3 M3GNet как графовая модель атомистических систем	8
3.4 MatterSim как универсальная предобученная модель	10
3.5 MACE как эквивариантная модель для силовых полей	11
3.6 Что именно сравнивается в этой работе	13
4 Экспериментальный протокол	14
4.1 Данные и разбиения	14
4.2 Преобразование форматов данных	14
4.3 Процедуры обучения и оценки	14
5 Результаты и обсуждение	15
5.1 Organic	15
5.2 H ₂ O	15
5.3 MoNbTaVW	15
5.4 Сводное обсуждение	15
6 Ограничения исследования	16
7 Заключение	17
Список источников	18
А Приложения	18
A.1 Дополнительные таблицы	18

Аннотация

Здесь будет краткое описание цели, сравниваемых моделей, набора экспериментов и основных выводов. Финальные численные результаты не добавляются до сверки с источником истины.

Ключевые слова

машинно-обучаемые межатомные потенциалы; MACE; MatterSim; МТР; тонкая настройка; MAE; RMSE.

1. Введение

Атомистическое моделирование опирается на вычисление потенциальной энергии атомной системы и сил, действующих на атомы. Прямые квантово-механические расчеты дают физически обоснованные значения этих величин, но становятся дорогими при большом числе конфигураций. Машинно-обучаемые межатомные потенциалы решают эту задачу как задачу аппроксимации: модель получает атомную конфигурацию и предсказывает энергию, а силы обычно связываются с производными энергии по координатам атомов. Такая постановка делает задачу близкой к регрессии, но с дополнительными геометрическими требованиями к модели: атомная конфигурация задается не табличным вектором признаков, а набором типов атомов, координат и соседских взаимодействий [1, 2].

В этой работе задача регрессии рассматривается на примере машинно-обучаемых межатомных потенциалов. Целевыми величинами являются энергия системы и силы, а качество модели оценивается отдельно по ошибкам энергии и сил. Такое разделение нужно потому, что малая ошибка энергии сама по себе не гарантирует столь же точного восстановления сил: силы зависят от локальной формы потенциальной энергетической поверхности и чувствительны к ошибкам ее производных. Поэтому в экспериментальной части используются две группы метрик: MAE и RMSE по энергии в meV/atom и MAE и RMSE по силам в $\text{meV/\AA}$.

Основное сравнение строится между двумя стратегиями построения межатомных потенциалов. Первая стратегия — обучение специализированной модели с нуля на данных целевой системы. В этой роли используются МТР-потенциалы уровней МТР-16 и МТР-20, реализованные в инструментарии MLIP-4. МТР представляет атомное окружение через систематически расширяемый набор признаков и служит в работе базовой специализированной моделью, с которой сравниваются универсальные подходы [3, 4]. Вторая стратегия — тонкая настройка предобученных универсальных моделей на целевых данных. Для этой стратегии рассматриваются MatterSim и MACE.

Выбор MatterSim и MACE связан с разными способами построения универсальных межатомных потенциалов. MatterSim обучается как универсальная модель для широкого диапазона химических составов и условий; в исходной работе отдельно указывается возможность дальнейшей адаптации модели на предметно-специфических данных [5]. В проведенных экспериментах MatterSim использовался не как один общий checkpoint: для organic-датасета и H_2O модель инициализировалась из семейства mattersim-v1.0.0-1M.pth, а для MoNbTaVW — из mattersim-v1.0.0-5M.pth. MACE, в свою очередь, строится как эквивариантная модель с передачей сообщений и сообщениями повышенного порядка; эта архитектура специально разрабатывалась для точных силовых полей, где важна согласованная аппроксимация энергии и сил [2]. Практическая часть работы использует эти модели как предобученные потенциалы, которые затем дообучаются на тех же целевых системах, что и МТР-модели [6, 7].

Сравнение таких стратегий не сводится к вопросу, какая модель лучше вообще. Универсальная предобученная модель может иметь преимущество за счет переноса знаний из большого набора исходных данных, но итоговое качество зависит от целевой системы, разбиения данных, метрики и настроек тонкой настройки. Для MoNbTaVW это особенно существенно: в работе отдельно раз-

личаются MACE default и MACE-EW50, поскольку это разные протоколы настройки MACE, а не две записи одного и того же результата. По этой причине все выводы формулируются только для конкретной системы, разбиения и метрики.

Цель работы — исследовать задачу регрессии энергий и сил в атомистическом моделировании на примере сравнения тонкой настройки универсальных машинно-обучаемых межатомных потенциалов MatterSim и MACE с обучением MTP-потенциалов с нуля на целевых данных. Эксперименты проводятся на трех системах: organic-датасете, H₂O и многокомпонентном сплаве MoNbTaVW. Для organic-датасета дополнительно рассматривается перенос качества между температурами, а для H₂O и MoNbTaVW анализ проводится на отложенных validation-разбиениях.

Для достижения этой цели в работе фиксируется единый протокол подготовки, обучения, тонкой настройки и оценки моделей, включая преобразование атомистических данных между форматами, используемыми MTP, MACE и MatterSim. Для MTP рассматриваются уровни MTP-16 и MTP-20; для MatterSim и MACE используются тонко настроенные версии предобученных моделей. Для всех основных систем рассчитываются ошибки MAE и RMSE по энергиям и силам. Результаты представлены в виде таблиц и графиков, а их интерпретация отделяет контрольные метрики от train-метрик, которые используются как дополнительная диагностика обучения.

Дальнейший текст устроен следующим образом. В разделе 2 формулируется задача регрессии для энергий и сил и вводятся метрики качества. В разделе 3 описываются используемые модели и их роль в сравнении. В разделе 4 фиксируется экспериментальный протокол. В разделе 5 приводятся результаты по organic-датасету, H₂O и MoNbTaVW. В разделе 6 перечисляются ограничения исследования, связанные с данными, протоколом и областью применимости выводов.

2. Постановка задачи и метрики

В работе рассматривается задача регрессии для атомистических конфигураций. Каждая конфигурация задается набором атомов, их химическими типами, координатами и, для периодических систем, ячейкой. Для конфигурации X_s с n_s атомами известны эталонная энергия E_s^{ref} и эталонные силы $F_{s,i}^{\text{ref}} \in \mathbb{R}^3$, действующие на атом i . Модель должна построить приближение энергии $\hat{E}_\theta(X_s)$ и соответствующих сил $\hat{F}_{\theta,s,i}$. В межатомных потенциалах силы обычно рассматриваются как производные энергии по координатам атомов:

$$\hat{F}_{\theta,s,i} = -\nabla_{\mathbf{r}_{s,i}} \hat{E}_\theta(X_s). \quad (1)$$

Эта связь делает задачу более жесткой, чем обычная регрессия одной скалярной величины: модель должна не только приблизить значения энергии, но и корректно восстановить локальную форму потенциальной энергетической поверхности. Такая постановка используется в современных графовых межатомных потенциалах, где атомная структура представляется как граф, а энергия и силы оцениваются согласованно [1, 2].

Сравнение в работе проводится не между отдельными запусками моделей, а между двумя стратегиями построения потенциала. Первая стратегия — обучение специализированного потенциала с нуля на целевом наборе данных. Для нее используются МТР-16 и МТР-20. Вторая стратегия — использование универсальной предобученной модели и ее тонкая настройка на той же целевой системе. Для этой стратегии рассматриваются MatterSim и MACE. Такая постановка нужна, чтобы отделить вклад предобучения и последующей адаптации от качества модели, обученной только на локальных данных целевой системы.

Эксперименты проводятся на трех системах: organic-датасете, H₂O и MoNbTaVW. Для organic-датасета рассматривается перенос между температурными режимами: модели обучаются на конфигурациях, связанных с 300 K, а качество оценивается на разбиениях test_300K, test_600K и test_1200K. Для H₂O и MoNbTaVW контрольная оценка проводится на валидационных разбиениях.

2.1. Метрики качества

Качество оценивается отдельно по энергиям и силам. Для энергии используется ошибка на атом: энергия конфигурации нормируется на число атомов, после чего сравнивается с эталонным значением. Если обозначить ошибку энергии на атом для конфигурации s через

$$\Delta\epsilon_s = \hat{\epsilon}_s - \epsilon_s^{\text{ref}},$$

то средняя абсолютная ошибка и среднеквадратичная ошибка по энергиям имеют вид

$$\text{MAE}_E = \frac{1}{S} \sum_{s=1}^S |\Delta\epsilon_s|, \quad \text{RMSE}_E = \sqrt{\frac{1}{S} \sum_{s=1}^S (\Delta\epsilon_s)^2}, \quad (2)$$

где S — число конфигураций в рассматриваемом разбиении. В итоговых таблицах ошибки энергии приводятся в meV/atom.

Для сил ошибка считается по атомам и координатным компонентам. Пусть

$$\Delta F_{s,i,k} = \hat{F}_{s,i,k} - F_{s,i,k}^{\text{ref}},$$

где i — номер атома, а $k \in \{x, y, z\}$ — координатная компонента силы. Тогда метрики по силам задаются как

$$\text{MAE}_{\text{forces}} = \frac{1}{3 \sum_{s=1}^S n_s} \sum_{s=1}^S \sum_{i=1}^{n_s} \sum_{k=1}^3 |\Delta F_{s,i,k}|, \quad \text{RMSE}_{\text{forces}} = \sqrt{\frac{1}{3 \sum_{s=1}^S n_s} \sum_{s=1}^S \sum_{i=1}^{n_s} \sum_{k=1}^3 (\Delta F_{s,i,k})^2}. \quad (3)$$

В итоговых таблицах ошибки сил приводятся в meV/Å.

Разделение метрик по энергиям и силам принципиально для интерпретации результатов. Модель может давать меньшую ошибку по энергии, но не быть лучшей по силам, и наоборот. Поэтому в работе не вводится единый усредненный рейтинг моделей: сравнение проводится отдельно для MAE по энергии, RMSE по энергии, MAE по силам и RMSE по силам. Это особенно важно при сопоставлении MatterSim и MACE, а также при анализе протоколов MACE default и MACE-EW50 для MoNbTaVW.

2.2. Правила интерпретации разбиений

Метрики на обучающем разбиении используются как диагностический показатель: они помогают понять, насколько хорошо модель подогналась под обучающие конфигурации. Основные выводы о качестве делаются по контрольным разбиениям: test_300K, test_600K, test_1200K для organic-датасета и валидационным разбиениям для H2O и MoNbTaVW. Такой порядок нужен, чтобы не смешивать качество подгонки на обучающих данных с оценкой переноса на новые конфигурации.

Для organic-датасета контрольные разбиения при разных температурах используются как проверка переноса качества. Ошибка на test_300K характеризует качество на температурном режиме, близком к обучающему, а test_600K и test_1200K позволяют оценить, насколько модель сохраняет качество при изменении температурного режима. Для H2O и MoNbTaVW интерпретация другая: здесь рассматривается качество на отложенном валидационном разбиении, а не перенос между температурами.

Все последующие сравнения в отчете формулируются с указанием системы, разбиения, модели и метрики. Это ограничение важно, поскольку преимущество конкретной модели не является абсолютным: оно может меняться при переходе от энергии к силам, от MAE к RMSE и от одной атомистической системы к другой.

3. Обзор литературы и используемые модели

3.1. Машинно-обучаемые межатомные потенциалы

Машинно-обучаемые межатомные потенциалы приближают потенциальную энергетическую поверхность атомной системы. Для конфигурации X , состоящей из атомных типов, координат и, при необходимости, периодической ячейки, модель строит приближение энергии

$$\hat{E}_\theta(X),$$

а силы связываются с производными этой энергии по координатам атомов:

$$\hat{\mathbf{F}}_{\theta,i} = -\nabla_{\mathbf{r}_i} \hat{E}_\theta(X).$$

Эта связь уже была использована в постановке задачи, но в обзоре моделей она задает главный критерий выбора архитектур: модель должна не только возвращать скалярную энергию, но и задавать достаточно гладкую и геометрически согласованную энергетическую поверхность, чтобы производные давали физически осмысленные силы.

Большинство современных машинно-обучаемых потенциалов используют локальное разложение энергии. В обобщенной форме его можно записать как

$$\hat{E}_\theta(X) = \sum_{i=1}^N \hat{E}_{\theta,i}(\mathcal{N}_i),$$

где $\mathcal{N}_i$ — локальное окружение атома i , определяемое соседями в радиусе отсечения. Это разложение не является специфичным для одной модели: оно задает общий язык для MTP, M3GNet, MACE и MatterSim. Различия между ними начинаются в том, как именно кодируется окружение $\mathcal{N}_i$, как учитываются симметрии и используется ли предобучение.

Для данной работы важны две стратегии построения потенциала. Первая стратегия — обучить специализированную модель только на целевых данных. Так используются MTP-потенциалы. Вторая стратегия — взять универсальную предобученную модель и адаптировать ее к целевой системе. Так используются MatterSim и MACE. Поэтому обзор ниже не перечисляет все существующие MLIP, а разбирает модели, которые задают это сравнение.

3.2. MTP как специализированный потенциал

Moment Tensor Potentials были предложены как систематически улучшаемый класс межатомных потенциалов, в котором локальное окружение атома описывается через моментные тензоры [3]. Для атома i с соседями j в радиусе отсечения вводятся относительные радиус-векторы

$$\mathbf{r}_{ij} = \mathbf{r}_j - \mathbf{r}_i.$$

Моментный тензор можно записать в обобщенном виде как

$$M_{\mu,\nu}(\mathcal{N}_i) = \sum_{j \in \mathcal{N}_i} f_{\mu}(|\mathbf{r}_{ij}|, z_i, z_j) \mathbf{r}_{ij}^{\otimes \nu},$$

где z_i и z_j — химические типы атомов, f_{μ} — радиальная функция, а $\mathbf{r}_{ij}^{\otimes \nu}$ обозначает тензорное произведение радиус-вектора с самим собой ν раз. Эта формула показывает, что МТР кодирует локальное окружение не только через расстояния, но и через направления на соседей. После свертки индексов из таких тензоров строятся инвариантные базисные функции $B_{\alpha}(\mathcal{N}_i)$, а атомный вклад в энергию задается линейной комбинацией:

$$\hat{E}_{\theta,i}(\mathcal{N}_i) = \sum_{\alpha} c_{\alpha} B_{\alpha}(\mathcal{N}_i).$$

Здесь обучаемыми параметрами являются коэффициенты c_{α} . Для этой работы это важно: МТР выступает как специализированный потенциал с явно контролируемым базисом, а не как большая предобученная нейросетевая модель.

Практическая работа с МТР в проекте выполнялась через MLIP-4 [4]. Статью MLIP-3 можно использовать как контекст по современной линии MLIP-пакетов для построения МТР и активного обучения, но не как точное описание использованной версии MLIP-4 [8]. Поэтому в тексте разделяются три уровня: статья Sharееv описывает математическую основу МТР, MLIP-4 фиксирует использованный программный инструментарий, а MLIP-3 дает контекст развития пакетов для МТР.

Уровни МТР-16 и МТР-20 в работе задают разные наборы базисных функций. В использованных запусках МТР-16 соответствует 122 базисным функциям, МТР-20 — 390. Число обучаемых параметров при этом не определяется только уровнем потенциала: оно также зависит от набора химических элементов и радиального базиса. В экспериментах использовался RadialBasisCinf(size=8); при этих настройках число параметров составляло 608 и 932 для organic-датасета, 222 и 450 для H₂O, 897 и 1293 для MoNbTaVW для уровней МТР-16 и МТР-20 соответственно. Эти числа нужны не для ранжирования моделей сами по себе, а для интерпретации МТР как специализированной базовой линии с контролируемой сложностью.

Роль МТР в сравнении не сводится к роли заведомо простой модели. Он обучается на тех же целевых данных, что и дообучаемые MatterSim и MACE, но не использует широкое предобучение. Поэтому сравнение с МТР показывает, насколько тонкая настройка универсального потенциала дает выигрыш относительно модели, которая строит приближение только из целевого набора данных.

3.3. M3GNet как графовая модель атомистических систем

M3GNet строит межатомный потенциал на графовом представлении структуры [1]. Атомы задаются вершинами, связи между соседними атомами — ребрами, координаты атомов и матрица

ячейки входят в описание структуры. В статье это представлено как граф

$$G = (V, E, X, [M, u]),$$

где V содержит атомные признаки, E — признаки связей, X — координаты атомов, M — матрицу ячейки, а u — дополнительные глобальные признаки, например температуру или давление, если они используются. Такая запись важна для нашей задачи: она явно отделяет химическую информацию от геометрической и позволяет затем получать силы через дифференцирование энергии по координатам.

Ключевой вклад M3GNet — добавление трехчастичных взаимодействий в графовую модель. В обобщенном виде обновление ребра e_{ij} через n -частичное взаимодействие в статье записывается как

$$\tilde{e}_{ij} = \sum_{\substack{k_1, k_2, \dots, k_{n-2} \in \mathcal{N}_i / j \\ k_1 \neq k_2 \neq \dots \neq k_{n-2}}} \phi_n(e_{ij}, \mathbf{r}_{ij}, v_j, \mathbf{r}_{ik_1}, \dots, \mathbf{r}_{ik_{n-2}}, v_{k_1}, \dots, v_{k_{n-2}}).$$

Для M3GNet основное внимание уделяется случаю трехчастичных взаимодействий. Тогда информация о соседнем атоме k используется не только через расстояния, но и через угол θ_{jik} между связями ij и ik . В статье это реализуется через разложение углового взаимодействия по сферическим функциям и радиальному базису:

$$\tilde{e}_{ij} = \sum_k j_l \left(z_{ln} \frac{r_{ik}}{r_c} \right) Y_l^0(\theta_{jik}) \odot \sigma(W_v v_k + b_v) f_c(r_{ij}) f_c(r_{ik}),$$

где j_l — сферическая функция Бесселя, Y_l^0 — сферическая гармоника, f_c — функция отсечения, а $\odot$ обозначает покомпонентное произведение. Для отчета не требуется подробно разбирать каждый множитель; важен смысл формулы: M3GNet добавляет в обновление связи информацию о тройках атомов и углах, то есть расширяет описание локальной геометрии за пределы попарных расстояний.

После учета многочастичных взаимодействий M3GNet выполняет последовательные обновления ребер, атомных признаков и, при наличии, глобального состояния:

$$\begin{aligned} e'_{ij} &= e_{ij} + \phi_e(v_i \oplus v_j \oplus e_{ij} \oplus u) W_e^0 e_{ij}^0, \\ v'_i &= v_i + \sum_j \phi'_e(v_i \oplus v_j \oplus e'_{ij} \oplus u) W_e^{0'} e_{ij}^0. \end{aligned}$$

Здесь $\oplus$ обозначает конкатенацию признаков. Эти формулы показывают, что информация накапливается через локальные связи, но атомный признак после нескольких обновлений уже содержит сведения о более широком окружении.

Для построения межатомного потенциала M3GNet предсказывает энергию, а силы и напряжения получает через автоматическое дифференцирование:

$$\mathbf{f} = -\frac{\partial E}{\partial \mathbf{x}}, \quad \sigma = V^{-1} \frac{\partial E}{\partial \varepsilon},$$

где $\mathbf{x}$ — координаты атомов, V — объем, ε — деформация [1]. Для нашего сравнения это принципиально: качество по силам проверяет не независимую векторную голову модели, а согласованность выученной энергетической поверхности с ее производными.

В статье M3GNet функция потерь включает энергию, силы и, для неорганических систем, напряжения:

$$\mathcal{L} = \ell(e, e_D) + w_f \ell(\mathbf{f}, \mathbf{f}_D) + w_\sigma \ell(\sigma, \sigma_D),$$

где ℓ — функция потерь Хьюбера, а индекс D обозначает данные из квантово-механического расчета [1]. Эта формула важна как пример того, что обучение межатомного потенциала обычно балансирует несколько физических величин. В нашей работе итоговая оценка также разделяется на ошибки энергии и сил, но сравнение проводится уже через MAE и RMSE, введенные в разделе 2.

3.4. MatterSim как универсальная предобученная модель

MatterSim предложен как универсальная предобученная модель для атомистического моделирования в широком пространстве химических составов и термодинамических условий [5]. В статье модель позиционируется как потенциал, обученный на конфигурациях, покрывающих элементы периодической таблицы, температуры от 0 до 5000 K и давления до 1000 GPa. Для этой работы важен не сам масштаб предобучения как рекламная характеристика, а его экспериментальная роль: MatterSim начинает адаптацию не со случайной инициализации, а с параметров, уже полученных на широком наборе атомистических данных.

Архитектурно MatterSim не нужно сводить к одной модели. В статье указано, что в MatterSim используются две графовые основы: M3GNet и Graphormer [5]. M3GNet описан выше как графовая модель с трехчастичными взаимодействиями. Graphormer относится к трансформерным графовым архитектурам; в MatterSim он используется для вариантов, где требуется более высокая емкость модели, но цена такой емкости — более высокая стоимость вывода и требования к памяти. В этом отчете нельзя утверждать, что все использованные контрольные точки MatterSim имеют один и тот же backbone, если это не подтверждено логами конкретного запуска.

Обобщенно MatterSim можно описать как отображение

$$X \mapsto \kappa_G \mapsto \hat{E}_\theta(X),$$

где X — атомная структура, а κ_G — глобальное представление графа после графовых обновлений или структурного кодировщика. В дополнительных материалах MatterSim такое глобальное представление далее преобразуется через отдельный декодер. Для M3GNet-ветки это можно записать как

$$\kappa'_G = \text{MLP}_1(\kappa_G) = \phi(W^2 \rho(W^1 \kappa_G + b_1) + b_2),$$

а для Graphormer-ветки как

$$\kappa'_G = \text{MLP}_2(\kappa_G) = W^2 \lambda(\rho(W^1 \kappa_G + b_1)) + b_2.$$

Эти формулы не нужны для ручного воспроизведения MatterSim, но они показывают, что модель

разделяет две части: получение представления структуры и декодирование этого представления в целевую физическую величину.

Для тонкой настройки MatterSim используется обычная идея адаптации предобученной модели: параметры θ_{pre} , полученные на широком наборе данных, становятся начальной точкой оптимизации на целевом наборе:

$$\theta_{\text{ft}} = \arg \min_{\theta} \mathcal{L}_{D_{\text{target}}}(\theta), \quad \theta \text{ инициализируется из } \theta_{\text{pre}}.$$

Документация MatterSim описывает такую настройку как штатный режим работы с моделью [7]. Для нашего сравнения это означает, что MatterSim представляет стратегию «широкое предобучение + адаптация к целевой системе». В разделе результатов эта стратегия сравнивается с МТР, который обучается на целевых данных без такого предобучения.

3.5. МАСЕ как эквивариантная модель для силовых полей

МАСЕ строится как графовая модель с эквивариантной передачей сообщений, то есть message passing [2]. В стандартной схеме графовой передачи сообщений состояние атома i на слое t можно записать как

$$\sigma_i^{(t)} = (\mathbf{r}_i, z_i, h_i^{(t)}),$$

где $\mathbf{r}_i$ — координаты, z_i — химический элемент, $h_i^{(t)}$ — обучаемые признаки. Сообщение к атому строится через соседей:

$$m_i^{(t)} = \bigoplus_{j \in \mathcal{N}(i)} M_t(\sigma_i^{(t)}, \sigma_j^{(t)}),$$

после чего признаки обновляются:

$$h_i^{(t+1)} = U_t(\sigma_i^{(t)}, m_i^{(t)}).$$

В МАСЕ, как и в других потенциалах с локальным разложением энергии, итоговая энергия собирается из атомных вкладов:

$$E_i = \sum_{t=1}^T R_t(\sigma_i^{(t)}).$$

Эквивариантность означает, что внутренние признаки модели должны изменяться согласованно с поворотом или отражением атомной структуры. Для преобразования $Q \in O(3)$ это условие записывается как

$$h_i^{(t)}(Q \cdot (\mathbf{r}_1, \dots, \mathbf{r}_N)) = D(Q) h_i^{(t)}(\mathbf{r}_1, \dots, \mathbf{r}_N),$$

где $D(Q)$ — матрица представления преобразования Q [2]. Для скалярной энергии это особенно важно: при повороте всей структуры энергия не должна меняться, но векторные и тензорные внутренние признаки могут преобразовываться не тривиально. Такая конструкция дает модели возможность работать с геометрией, не нарушая физических симметрий.

Главная архитектурная идея МАСЕ — сообщения повышенного порядка. В статье сообщение

записывается как иерархическое разложение по корреляционному порядку:

$$m_i^{(t)} = \sum_j u_1^{(t)}(\sigma_i^{(t)}; \sigma_j^{(t)}) + \sum_{j_1, j_2} u_2^{(t)}(\sigma_i^{(t)}; \sigma_{j_1}^{(t)}, \sigma_{j_2}^{(t)}) + \dots + \sum_{j_1, \dots, j_\nu} u_\nu^{(t)}(\sigma_i^{(t)}; \sigma_{j_1}^{(t)}, \dots, \sigma_{j_\nu}^{(t)}).$$

Эта формула показывает отличие MACE от моделей, где каждое сообщение фактически описывает только пару атомов. MACE пытается включить более сложные локальные взаимодействия непосредственно в сообщение, а не только накапливать их большим числом слоев.

Для построения таких сообщений MACE сначала формирует двухчастичные признаки $A_i^{(t)}$, в которых используются радиальные функции, сферические гармоники и признаки соседнего атома. В упрощенной записи первого слоя это выглядит как

$$A_{i,klm}^{(1)} = \sum_{j \in \mathcal{N}(i)} R_{kl}^{(1)}(r_{ji}) Y_{lm}(\hat{\mathbf{r}}_{ji}) W_{kz_j}^{(1)}.$$

Здесь $R_{kl}^{(1)}$ кодирует расстояние, Y_{lm} — направление на соседа, а $W_{kz_j}^{(1)}$ зависит от химического типа атома j . Затем признаки повышенного порядка строятся через тензорные произведения и симметризацию:

$$B_{i,\eta_\nu kLM}^{(t)} = \sum_{\mathbf{lm}} C_{\eta_\nu, \mathbf{lm}}^{LM} \prod_{\xi=1}^{\nu} \sum_{\tilde{k}} w_{kkl\xi}^{(t)} A_{i,kl\xi m_\xi}^{(t)}.$$

Коэффициенты $C_{\eta_\nu, \mathbf{lm}}^{LM}$ обеспечивают нужные свойства преобразования признаков, а произведение по ξ соответствует корреляционному порядку. Для отчета важно не техническое устройство этих коэффициентов, а смысл: MACE строит признаки, которые кодируют многочастичную геометрию окружения и при этом сохраняют контролируемое поведение при поворотах и отражениях структуры.

Сообщение MACE после этого записывается как линейная комбинация таких признаков:

$$m_{i,kLM}^{(t)} = \sum_{\nu} \sum_{\eta_\nu} W_{z_{ikL}, \eta_\nu}^{(t)} B_{i,\eta_\nu kLM}^{(t)}.$$

Обновление признаков включает само сообщение и остаточную связь с предыдущим состоянием:

$$h_{i,kLM}^{(t+1)} = \sum_{\tilde{k}} W_{kL, \tilde{k}}^{(t)} m_{i, \tilde{k}LM}^{(t)} + \sum_{\tilde{k}} W_{z_{ikL}, \tilde{k}}^{(t)} h_{i, \tilde{k}LM}^{(t)}.$$

Энергия считается только из инвариантных признаков $h_{i,k00}^{(t)}$, чтобы атомные вклады в энергию оставались скалярными:

$$E_i = E_i^{(0)} + E_i^{(1)} + \dots + E_i^{(T)}, \quad E_i^{(t)} = R_t\left(\{h_{i,k00}^{(t)}\}_k\right).$$

Эта часть архитектуры напрямую связана с задачей регрессии силовых полей: модель использует геометрически богатые внутренние признаки, но итоговая энергия сохраняет правильную инвариантность.

В данной работе MACE представляет вторую универсальную стратегию наряду с MatterSim:

предобученная модель дообучается на целевой системе и затем сравнивается с МТР. Документация MACE описывает тонкую настройку как отдельный рабочий режим [6]. При этом MACE default и MACE-EW50 должны рассматриваться как разные протоколы настройки, а не как одна и та же модельная строка. Это различие будет использовано в разделе результатов для MoNbTaVW.

3.6. Что именно сравнивается в этой работе

Рассмотренные модели различаются не только реализациями, но и источником информации, доступной до обучения на целевой системе. МТР строит приближение с нуля по данным конкретной системы. MatterSim и MACE начинают с предобученных параметров и затем адаптируются на целевом наборе. Поэтому основное сравнение в работе можно записать как сравнение двух отображений:

$$D_{\text{target}} \mapsto \hat{E}_{\text{МТР}}, \quad (\theta_{\text{pre}}, D_{\text{target}}) \mapsto \hat{E}_{\text{universal,ft}},$$

где D_{target} — целевой набор данных, θ_{pre} — параметры предобученной универсальной модели, а $\hat{E}_{\text{universal,ft}}$ — энергия после тонкой настройки MatterSim или MACE.

Эта запись подчеркивает, что сравниваются не только архитектуры, но и режимы использования данных. МТР проверяет, чего можно добиться, обучаясь на целевой системе без внешнего предобучения. MatterSim и MACE проверяют, насколько помогает перенос информации из широкого предобучения при последующей адаптации. Такой дизайн особенно полезен для трех разных систем проекта: organic-датасета, H2O и MoNbTaVW, поскольку они различаются химическим составом и характером разбиений.

Из обзора также следует ограничение на интерпретацию результатов. Ни одна из архитектурных идей сама по себе не гарантирует лучшую ошибку по всем метрикам. МТР имеет контролируемый специализированный базис, M3GNet и MatterSim используют графовое представление атомистических данных, MACE дополнительно встраивает эквивариантность и сообщения повышенного порядка. Поэтому дальнейшие выводы должны формулироваться не как общее ранжирование моделей, а как утверждения вида: система, разбиение, модель, метрика.

В разделе результатов это означает, что отдельно анализируются Energy MAE, Energy RMSE, Forces MAE и Forces RMSE; отдельно различаются organic-датасет, H2O и MoNbTaVW; отдельно фиксируются MACE default и MACE-EW50. Такая дисциплина нужна, чтобы сравнение оставалось проверяемым: универсальная модель может быть сильнее в одном режиме и не быть лучшей в другом, а изменение протокола тонкой настройки может менять баланс ошибок энергии и сил.

4. Экспериментальный протокол

В этом разделе будет собран проверяемый протокол экспериментов. Детали должны соответствовать существующим документам репозитория и источнику истины.

4.1. Данные и разбиения

Здесь будет описано, какие системы входят в основную линию результатов и какие материалы относятся только к приложениям или проверкам.

4.2. Преобразование форматов данных

Для сравнения MTP, MACE и MatterSim требовалось привести одни и те же атомистические конфигурации к форматам, поддерживаемым разными инструментами. В проекте были подготовлены вспомогательные скрипты преобразования между ASE/extxyz, MLIP `.cfg` и JSON-представлением MLIP-4. При конвертации сохранялись атомные типы, координаты, ячейки, энергии и силы, поскольку эти величины используются при обучении и последующей оценке моделей. Эти скрипты сохранены в provenance-зоне clean hero как часть истории экспериментов; они не являются основной исполняемой точкой репозитория, но фиксируют, как обеспечивалась совместимость данных между MTP, MACE и MatterSim.

4.3. Процедуры обучения и оценки

Здесь будет описано, как были получены сравнимые результаты для моделей, без добавления неподтвержденных оценок стоимости вычислений.

5. Результаты и обсуждение

В этом разделе будут представлены таблицы, графики и обсуждение результатов по каждой системе. Сейчас численные значения намеренно не добавлены.

5.1. Organic

Здесь будет обсуждение результатов для organic-системы.

5.2. H₂O

Здесь будет обсуждение результатов для H₂O.

5.3. MoNbTaVW

Здесь будет обсуждение результатов для MoNbTaVW.

5.4. Сводное обсуждение

Здесь будет аккуратное сопоставление моделей без чрезмерных обобщений.

6. Ограничения исследования

В этом разделе будут описаны ограничения данных, протокола и интерпретации результатов.

Здесь также будут зафиксированы границы утверждений, которые нельзя расширять без дополнительных экспериментов.

7. Заключение

В этом разделе будут кратко подведены итоги исследования и указаны направления дальнейшей работы.

Формулировки заключения должны быть производными от уже проверенных результатов.

Список литературы

- [1] Chi Chen and Shyue Ping Ong. A universal graph deep learning interatomic potential for the periodic table. *Nature Computational Science*, 2:718--728, 2022.
- [2] Ilyes Batatia, Dávid Péter Kovács, Gregor N. C. Simm, Christoph Ortner, and Gábor Csányi. MACE: Higher order equivariant message passing neural networks for fast and accurate force fields. In *Advances in Neural Information Processing Systems*, 2022. TODO: verify final NeurIPS citation format before submission.
- [3] Alexander V. Shapeev. Moment tensor potentials: A class of systematically improvable interatomic potentials. *Multiscale Modeling & Simulation*, 14(3):1153--1173, 2016. TODO: use when describing the MTP baseline.
- [4] Alexander Shapeev, Max Hodapp, Evgeny Podryabinkin, David Demuriia, Dmitry Korogod, and Olga Chalykh. MLIP-4: Machine learning interatomic potentials software package. <https://gitlab.com/ashapeev/mlip-4>, 2024. Software repository; TODO: specify the version or commit used in experiments.
- [5] Han Yang, Chenxi Hu, Yichi Zhou, Xixian Liu, Yu Shi, Jielan Li, Guanzhi Li, Zekun Chen, Shuizhou Chen, Claudio Zeni, Matthew Horton, Robert Pinsler, Andrew Fowler, Daniel Zügner, Tian Xie, Jake Smith, Lixin Sun, Qian Wang, Lingyu Kong, Chang Liu, Hongxia Hao, and Ziheng Lu. MatterSim: A deep learning atomistic model across elements, temperatures and pressures. *arXiv preprint arXiv:2405.04967*, 2024. TODO: verify final publication status before submission.
- [6] MACE developers. MACE documentation: Fine-tuning. <https://mace-docs.readthedocs.io/en/latest/guide/finetuning.html>, 2026. Accessed 2026-05-29; TODO: pin documentation version before final build.
- [7] Microsoft. MatterSim readme: Fine-tuning mattersim models. <https://github.com/microsoft/mattersim>, 2026. Accessed 2026-05-29; TODO: specify commit or release before final build.
- [8] Evgeny Podryabinkin, Kamil Garifullin, Alexander Shapeev, and Ivan Novikov. MLIP-3: Active learning on atomic environments with moment tensor potentials. *arXiv preprint arXiv:2304.13144*, 2023. Software-method paper for the MLIP package line; not an exact description of MLIP-4.

А. Приложения

В приложениях будут размещены материалы, которые важны для воспроизводимости, но перегружают основной текст.

А.1. Дополнительные таблицы

Здесь будет место для расширенных таблиц и проверочных материалов.