

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет об исследовательском проекте
на тему
Изучение задачи регрессии в машинном обучении на примере машинно-обучаемых
межатомных потенциалов

Выполнен студентом:

Группы БПМИ245 _____ Маннанов Булат Рашитович
ФИО студента

Проверен руководителем проекта:

Новиков Иван Сергеевич, к. ф.-м. н.

ФИО, научная степень (если есть)

Доцент

Должность

Факультет компьютерных наук / Департамент больших данных и информационного поиска

Место работы (организация или департамент НИУ ВШЭ)

Москва 2026

Содержание

Аннотация	2
1 Введение	3
2 Постановка задачи и метрики	5
2.1 Метрики качества	5
2.2 Правила интерпретации разбиений	6
3 Обзор литературы и используемые модели	7
3.1 Машинно-обучаемые межатомные потенциалы	7
3.2 MTP как специализированный потенциал	7
3.3 M3GNet как графовая модель атомистических систем	8
3.4 MatterSim как универсальная предобученная модель	8
3.5 MACE как эквивариантная модель для силовых полей	9
3.6 Тонкая настройка универсальных моделей	10
3.7 Что именно сравнивается в этой работе	10
4 Экспериментальный протокол	11
4.1 Данные и разбиения	11
4.2 Преобразование форматов данных	11
4.3 Процедуры обучения и оценки	11
5 Результаты и обсуждение	12
5.1 Organic	12
5.2 H ₂ O	12
5.3 MoNbTaVW	12
5.4 Сводное обсуждение	12
6 Ограничения исследования	13
7 Заключение	14
Список источников	15
А Приложения	15
А.1 Дополнительные таблицы	15

Аннотация

Здесь будет краткое описание цели, сравниваемых моделей, набора экспериментов и основных выводов. Финальные численные результаты не добавляются до сверки с источником истины.

Ключевые слова

машинно-обучаемые межатомные потенциалы; MACE; MatterSim; МТР; тонкая настройка; MAE; RMSE.

1. Введение

Атомистическое моделирование опирается на вычисление потенциальной энергии атомной системы и сил, действующих на атомы. Прямые квантово-механические расчеты дают физически обоснованные значения этих величин, но становятся дорогими при большом числе конфигураций. Машинно-обучаемые межатомные потенциалы решают эту задачу как задачу аппроксимации: модель получает атомную конфигурацию и предсказывает энергию, а силы обычно связываются с производными энергии по координатам атомов. Такая постановка делает задачу близкой к регрессии, но с дополнительными геометрическими требованиями к модели: атомная конфигурация задается не табличным вектором признаков, а набором типов атомов, координат и соседских взаимодействий [1, 2].

В этой работе задача регрессии рассматривается на примере машинно-обучаемых межатомных потенциалов. Целевыми величинами являются энергия системы и силы, а качество модели оценивается отдельно по ошибкам энергии и сил. Такое разделение нужно потому, что малая ошибка энергии сама по себе не гарантирует столь же точного восстановления сил: силы зависят от локальной формы потенциальной энергетической поверхности и чувствительны к ошибкам ее производных. Поэтому в экспериментальной части используются две группы метрик: MAE и RMSE по энергии в meV/atom и MAE и RMSE по силам в $\text{meV/\AA}$.

Основное сравнение строится между двумя стратегиями построения межатомных потенциалов. Первая стратегия — обучение специализированной модели с нуля на данных целевой системы. В этой роли используются МТР-потенциалы уровней МТР-16 и МТР-20, реализованные в инструментарии MLIP-4. МТР представляет атомное окружение через систематически расширяемый набор признаков и служит в работе базовой специализированной моделью, с которой сравниваются универсальные подходы [3, 4]. Вторая стратегия — тонкая настройка предобученных универсальных моделей на целевых данных. Для этой стратегии рассматриваются MatterSim и MACE.

Выбор MatterSim и MACE связан с разными способами построения универсальных межатомных потенциалов. MatterSim обучается как универсальная модель для широкого диапазона химических составов и условий; в исходной работе отдельно указывается возможность дальнейшей адаптации модели на предметно-специфических данных [5]. В проведенных экспериментах MatterSim использовался не как один общий checkpoint: для organic-датасета и H₂O модель инициализировалась из семейства mattersim-v1.0.0-1M.pth, а для MoNbTaVW — из mattersim-v1.0.0-5M.pth. MACE, в свою очередь, строится как эквивариантная модель с передачей сообщений и сообщениями повышенного порядка; эта архитектура специально разрабатывалась для точных силовых полей, где важна согласованная аппроксимация энергии и сил [2]. Практическая часть работы использует эти модели как предобученные потенциалы, которые затем дообучаются на тех же целевых системах, что и МТР-модели [6, 7].

Сравнение таких стратегий не сводится к вопросу, какая модель лучше вообще. Универсальная предобученная модель может иметь преимущество за счет переноса знаний из большого набора исходных данных, но итоговое качество зависит от целевой системы, разбиения данных, метрики и настроек тонкой настройки. Для MoNbTaVW это особенно существенно: в работе отдельно раз-

личаются MACE default и MACE-EW50, поскольку это разные протоколы настройки MACE, а не две записи одного и того же результата. По этой причине все выводы формулируются только для конкретной системы, разбиения и метрики.

Цель работы — исследовать задачу регрессии энергий и сил в атомистическом моделировании на примере сравнения тонкой настройки универсальных машинно-обучаемых межатомных потенциалов MatterSim и MACE с обучением МТР-потенциалов с нуля на целевых данных. Эксперименты проводятся на трех системах: organic-датасете, H₂O и многокомпонентном сплаве MoNbTaVW. Для organic-датасета дополнительно рассматривается перенос качества между температурами, а для H₂O и MoNbTaVW анализ проводится на отложенных validation-разбиениях.

Для достижения этой цели в работе фиксируется единый протокол подготовки, обучения, тонкой настройки и оценки моделей, включая преобразование атомистических данных между форматами, используемыми МТР, MACE и MatterSim. Для МТР рассматриваются уровни МТР-16 и МТР-20; для MatterSim и MACE используются тонко настроенные версии предобученных моделей. Для всех основных систем рассчитываются ошибки MAE и RMSE по энергиям и силам. Результаты представлены в виде таблиц и графиков, а их интерпретация отделяет контрольные метрики от train-метрик, которые используются как дополнительная диагностика обучения.

Дальнейший текст устроен следующим образом. В разделе 2 формулируется задача регрессии для энергий и сил и вводятся метрики качества. В разделе 3 описываются используемые модели и их роль в сравнении. В разделе 4 фиксируется экспериментальный протокол. В разделе 5 приводятся результаты по organic-датасету, H₂O и MoNbTaVW. В разделе 6 перечисляются ограничения исследования, связанные с данными, протоколом и областью применимости выводов.

2. Постановка задачи и метрики

В работе рассматривается задача регрессии для атомистических конфигураций. Каждая конфигурация задается набором атомов, их химическими типами, координатами и, для периодических систем, ячейкой. Для конфигурации X_s с n_s атомами известны эталонная энергия E_s^{ref} и эталонные силы $F_{s,i}^{\text{ref}} \in \mathbb{R}^3$, действующие на атом i . Модель должна построить приближение энергии $\hat{E}_\theta(X_s)$ и соответствующих сил $\hat{F}_{\theta,s,i}$. В межатомных потенциалах силы обычно рассматриваются как производные энергии по координатам атомов:

$$\hat{F}_{\theta,s,i} = -\nabla_{\mathbf{r}_{s,i}} \hat{E}_\theta(X_s). \quad (1)$$

Эта связь делает задачу более жесткой, чем обычная регрессия одной скалярной величины: модель должна не только приблизить значения энергии, но и корректно восстановить локальную форму потенциальной энергетической поверхности. Такая постановка используется в современных графовых межатомных потенциалах, где атомная структура представляется как граф, а энергия и силы оцениваются согласованно [1, 2].

Сравнение в работе проводится не между отдельными запусками моделей, а между двумя стратегиями построения потенциала. Первая стратегия — обучение специализированного потенциала с нуля на целевом наборе данных. Для нее используются МТР-16 и МТР-20. Вторая стратегия — использование универсальной предобученной модели и ее тонкая настройка на той же целевой системе. Для этой стратегии рассматриваются MatterSim и MACE. Такая постановка нужна, чтобы отделить вклад предобучения и последующей адаптации от качества модели, обученной только на локальных данных целевой системы.

Эксперименты проводятся на трех системах: organic-датасете, H₂O и MoNbTaVW. Для organic-датасета рассматривается перенос между температурными режимами: модели обучаются на конфигурациях, связанных с 300 K, а качество оценивается на разбиениях test_300K, test_600K и test_1200K. Для H₂O и MoNbTaVW контрольная оценка проводится на валидационных разбиениях.

2.1. Метрики качества

Качество оценивается отдельно по энергиям и силам. Для энергии используется ошибка на атом: энергия конфигурации нормируется на число атомов, после чего сравнивается с эталонным значением. Если обозначить ошибку энергии на атом для конфигурации s через

$$\Delta\epsilon_s = \hat{\epsilon}_s - \epsilon_s^{\text{ref}},$$

то средняя абсолютная ошибка и среднеквадратичная ошибка по энергиям имеют вид

$$\text{MAE}_E = \frac{1}{S} \sum_{s=1}^S |\Delta\epsilon_s|, \quad \text{RMSE}_E = \sqrt{\frac{1}{S} \sum_{s=1}^S (\Delta\epsilon_s)^2}, \quad (2)$$

где S — число конфигураций в рассматриваемом разбиении. В итоговых таблицах ошибки энергии приводятся в meV/atom.

Для сил ошибка считается по атомам и координатным компонентам. Пусть

$$\Delta F_{s,i,k} = \hat{F}_{s,i,k} - F_{s,i,k}^{\text{ref}},$$

где i — номер атома, а $k \in \{x, y, z\}$ — координатная компонента силы. Тогда метрики по силам задаются как

$$\text{MAE}_{\text{forces}} = \frac{1}{3 \sum_{s=1}^S n_s} \sum_{s=1}^S \sum_{i=1}^{n_s} \sum_{k=1}^3 |\Delta F_{s,i,k}|, \quad \text{RMSE}_{\text{forces}} = \sqrt{\frac{1}{3 \sum_{s=1}^S n_s} \sum_{s=1}^S \sum_{i=1}^{n_s} \sum_{k=1}^3 (\Delta F_{s,i,k})^2}. \quad (3)$$

В итоговых таблицах ошибки сил приводятся в meV/Å.

Разделение метрик по энергиям и силам принципиально для интерпретации результатов. Модель может давать меньшую ошибку по энергии, но не быть лучшей по силам, и наоборот. Поэтому в работе не вводится единый усредненный рейтинг моделей: сравнение проводится отдельно для MAE по энергии, RMSE по энергии, MAE по силам и RMSE по силам. Это особенно важно при сопоставлении MatterSim и MACE, а также при анализе протоколов MACE default и MACE-EW50 для MoNbTaVW.

2.2. Правила интерпретации разбиений

Метрики на обучающем разбиении используются как диагностический показатель: они помогают понять, насколько хорошо модель подогналась под обучающие конфигурации. Основные выводы о качестве делаются по контрольным разбиениям: test_300K, test_600K, test_1200K для organic-датасета и валидационным разбиениям для H2O и MoNbTaVW. Такой порядок нужен, чтобы не смешивать качество подгонки на обучающих данных с оценкой переноса на новые конфигурации.

Для organic-датасета контрольные разбиения при разных температурах используются как проверка переноса качества. Ошибка на test_300K характеризует качество на температурном режиме, близком к обучающему, а test_600K и test_1200K позволяют оценить, насколько модель сохраняет качество при изменении температурного режима. Для H2O и MoNbTaVW интерпретация другая: здесь рассматривается качество на отложенном валидационном разбиении, а не перенос между температурами.

Все последующие сравнения в отчете формулируются с указанием системы, разбиения, модели и метрики. Это ограничение важно, поскольку преимущество конкретной модели не является абсолютным: оно может меняться при переходе от энергии к силам, от MAE к RMSE и от одной атомистической системы к другой.

3. Обзор литературы и используемые модели

3.1. Машинно-обучаемые межатомные потенциалы

Машинно-обучаемые межатомные потенциалы приближают потенциальную энергетическую поверхность атомной системы. Для обзора моделей здесь достаточно зафиксировать общий принцип, который объединяет MTP, M3GNet, MatterSim и MACE: энергия структуры представляется через вклады локальных атомных окружений,

$$\hat{E}_\theta(X) = \sum_{i=1}^N \hat{E}_{\theta,i}(\mathcal{N}_i).$$

Здесь $\mathcal{N}_i$ — окружение атома i , определяемое соседями в радиусе отсечения. Различие между моделями состоит не в самой идее локальности, а в том, как кодируется окружение, какие симметрии встроены в архитектуру и используются ли параметры, полученные до обучения на целевой системе.

Для экспериментов важны две стратегии. Первая стратегия — обучить специализированный потенциал только на данных целевой системы; так используются MTP-16 и MTP-20. Вторая стратегия — взять универсальную предобученную модель и донастроить ее на тех же данных; так используются MatterSim и MACE. Поэтому обзор ниже не перечисляет все семейства MLIP, а объясняет только те свойства моделей, которые влияют на это сравнение.

3.2. MTP как специализированный потенциал

Moment Tensor Potentials были предложены как систематически улучшаемый класс межатомных потенциалов, где локальное окружение атома описывается через моментные тензоры [3]. Для атома i с соседями j в радиусе отсечения вводятся относительные радиус-векторы $\mathbf{r}_{ij} = \mathbf{r}_j - \mathbf{r}_i$, а моментный тензор можно записать в обобщенном виде:

$$M_{\mu,\nu}(\mathcal{N}_i) = \sum_{j \in \mathcal{N}_i} f_\mu(|\mathbf{r}_{ij}|, z_i, z_j) \mathbf{r}_{ij}^{\otimes \nu}.$$

Здесь z_i и z_j — химические типы атомов, f_μ — радиальная функция, а $\mathbf{r}_{ij}^{\otimes \nu}$ кодирует направленную геометрию окружения. После свертки индексов из таких тензоров строятся инвариантные базисные функции $B_\alpha(\mathcal{N}_i)$, и атомный вклад в энергию задается линейной комбинацией:

$$\hat{E}_{\theta,i}(\mathcal{N}_i) = \sum_{\alpha} c_{\alpha} B_{\alpha}(\mathcal{N}_i).$$

Обучаемые параметры здесь — коэффициенты c_{α} . Поэтому MTP в этой работе играет роль специализированной базовой линии с явно заданным базисом, а не предобученной нейросетевой модели.

Практическая работа с MTP выполнялась через MLIP-4 [4]. Статья MLIP-3 используется только как контекст по современной линии MLIP-пакетов для построения MTP и активного обучения, но не как точное описание использованной версии MLIP-4 [8].

Уровни МТР-16 и МТР-20 задают разные наборы базисных функций: в использованных запусках МТР-16 соответствует 122 базисным функциям, МТР-20 — 390. Число обучаемых параметров зависит не только от уровня, но и от набора химических элементов и радиального базиса. В экспериментах использовался RadialBasisCinf(size=8); при этих настройках число параметров составляло 608 и 932 для organic-датасета, 222 и 450 для H₂O, 897 и 1293 для MoNbTaVW для уровней МТР-16 и МТР-20 соответственно. Эти числа не ранжируют модели сами по себе, но показывают, как менялась сложность специализированной МТР-базовой линии.

3.3. M3GNet как графовая модель атомистических систем

M3GNet строит межатомный потенциал на графовом представлении атомной структуры [1]. В статье структура задается как

$$G = (V, E, X, [M, u]),$$

где V содержит атомные признаки, E — признаки связей, X — координаты атомов, M — матрицу ячейки, а u — дополнительные глобальные признаки, например температуру или давление. Такая запись полезна для отчета, потому что отделяет химическую информацию от геометрии и показывает, почему графовые модели естественно применять к атомистическим конфигурациям.

Конкретный вклад M3GNet для этого обзора — учет трехчастичных взаимодействий. В сокращенной форме обновление связи e_{ij} можно записать как

$$\tilde{e}_{ij} = \sum_{k \in \mathcal{N}_i/j} \phi_3(e_{ij}, \mathbf{r}_{ij}, v_j, \mathbf{r}_{ik}, v_k).$$

Эта формула передает смысл архитектурной идеи без деталей реализации: связь между атомами i и j обновляется с учетом третьего атома k . Для регрессии сил это важно, потому что локальная геометрия окружения часто зависит не только от попарных расстояний, но и от угловых отношений между соседями.

M3GNet предсказывает энергию, а силы получает как производные энергии по координатам:

$$\mathbf{f} = -\frac{\partial E}{\partial \mathbf{x}}.$$

Это связывает статью M3GNet с метриками работы: ошибка по силам проверяет не отдельный произвольный векторный выход, а согласованность выученной энергетической поверхности с ее производными.

3.4. MatterSim как универсальная предобученная модель

MatterSim предложен как универсальная предобученная модель для атомистического моделирования в широком пространстве химических составов и термодинамических условий [5]. В статье модель обучается на конфигурациях, покрывающих элементы периодической таблицы, температуры от 0 до 5000 К и давления до 1000 GPa. В этой работе этот масштаб важен как источник

начальных параметров: MatterSim начинает адаптацию не со случайной инициализации, а с представлений, полученных на широком наборе атомистических данных.

MatterSim не следует описывать как одну фиксированную архитектуру. В статье указаны две графовые основы, M3GNet и Graphormer [5]. Поэтому в отчете корректнее говорить, что MatterSim представляет семейство универсальных потенциалов на графовых архитектурах, а не приписывать всем использованным контрольным точкам модели один и тот же backbone без подтверждения логичности конкретного запуска.

Для сравнения с МТР MatterSim представляет стратегию «широкое предобучение плюс адаптация». Документация MatterSim описывает тонкую настройку на пользовательских данных как штатный режим работы с моделью [7]. Поэтому MatterSim в результатах нужно интерпретировать не только как архитектуру, но и как способ использовать внешнее предобучение перед обучением на organic-датасете, H2O или MoNbTaVW.

3.5. MACE как эквивариантная модель для силовых полей

MACE строится как графовая модель с эквивариантной передачей сообщений [2]. В общей схеме сообщение к атому i на слое t агрегируется по соседям:

$$m_i^{(t)} = \bigoplus_{j \in \mathcal{N}(i)} M_t(\sigma_i^{(t)}, \sigma_j^{(t)}).$$

Эта запись фиксирует роль локального окружения: атом получает информацию от соседей, а итоговая энергия затем собирается из атомных вкладов.

Главное отличие MACE от обычного message passing — эквивариантность относительно преобразований $Q \in O(3)$. В сокращенной форме условие можно записать так:

$$h_i^{(t)}(Q \cdot X) = D(Q)h_i^{(t)}(X).$$

Скалярная энергия должна оставаться инвариантной к повороту или отражению всей структуры, но внутренние признаки могут преобразовываться согласованно с геометрией. Для задачи силовых полей это не декоративное свойство: силы являются векторными величинами, поэтому модель должна учитывать симметрии пространства при аппроксимации энергетической поверхности.

Вторая архитектурная идея MACE — сообщения повышенного порядка. В статье сообщение представляется как сумма вкладов разного корреляционного порядка:

$$m_i^{(t)} = \sum_j u_1^{(t)}(\sigma_i^{(t)}; \sigma_j^{(t)}) + \sum_{j_1, j_2} u_2^{(t)}(\sigma_i^{(t)}; \sigma_{j_1}^{(t)}, \sigma_{j_2}^{(t)}) + \dots$$

Эта формула объясняет, почему MACE рассматривается отдельно от MatterSim: модель явно строит более сложные локальные взаимодействия внутри сообщений, а не полагается только на последовательное накопление попарной информации многими слоями.

В этой работе MACE представляет вторую универсальную стратегию наряду с MatterSim: предобученная модель дообучается на целевой системе и затем сравнивается с МТР. Документация

MACE описывает тонкую настройку как отдельный рабочий режим [6]. Конкретные режимы дообучения нельзя смешивать: MACE default и MACE-EW50 далее рассматриваются как разные протоколы, а не как одна модельная строка.

3.6. Тонкая настройка универсальных моделей

Тонкая настройка в этой работе рассматривается как адаптация предобученного потенциала к целевой атомистической системе. В отличие от МТР, где параметры подбираются с нуля на целевых данных, MatterSim и MACE начинают оптимизацию с параметров предобученной модели:

$$\theta^{(0)} = \theta_{\text{pre}}, \quad \theta_{\text{ft}} = \arg \min_{\theta} (w_E \mathcal{L}_E(D_{\text{target}}; \theta) + w_F \mathcal{L}_F(D_{\text{target}}; \theta)).$$

Здесь D_{target} — данные целевой системы, а w_E и w_F задают относительный вклад ошибок энергии и сил при обучении. Формула не фиксирует конкретную реализацию MatterSim или MACE; она задает различие между локальным обучением специализированного потенциала и адаптацией универсальной модели.

Для сравнения с МТР это различие принципиально: МТР использует только целевые данные, а MatterSim и MACE совмещают широкое предобучение и локальную адаптацию. Документации MatterSim и MACE описывают тонкую настройку как штатный сценарий работы с пользовательскими данными [7, 6]. Настройки тонкой настройки нужно фиксировать отдельно, поэтому MACE default и MACE-EW50 далее рассматриваются как разные протоколы, а не как одна строка результатов.

3.7. Что именно сравнивается в этой работе

Рассмотренные модели различаются не только архитектурами, но и источником информации до обучения на целевой системе. МТР строит приближение с нуля по данным конкретной системы. MatterSim и MACE начинают с предобученных параметров и затем адаптируются на целевом наборе. Основное сравнение можно записать как

$$D_{\text{target}} \mapsto \hat{E}_{\text{МТР}}, \quad (\theta_{\text{pre}}, D_{\text{target}}) \mapsto \hat{E}_{\text{universal,ft}}.$$

Здесь D_{target} — целевой набор данных, θ_{pre} — параметры предобученной универсальной модели, а $\hat{E}_{\text{universal,ft}}$ — энергия после тонкой настройки MatterSim или MACE.

Эта запись задает границы интерпретации результатов. Нельзя делать общий вывод, что универсальная модель лучше специализированной: преимущество может зависеть от системы, разбиения и метрики. Поэтому в разделе результатов отдельно рассматриваются organic-датасет, H2O и MoNbTaVW; отдельно анализируются Energy MAE, Energy RMSE, Forces MAE и Forces RMSE; отдельно фиксируются MACE default и MACE-EW50.

4. Экспериментальный протокол

В этом разделе будет собран проверяемый протокол экспериментов. Детали должны соответствовать существующим документам репозитория и источнику истины.

4.1. Данные и разбиения

Здесь будет описано, какие системы входят в основную линию результатов и какие материалы относятся только к приложениям или проверкам.

4.2. Преобразование форматов данных

Для сравнения MTP, MACE и MatterSim требовалось привести одни и те же атомистические конфигурации к форматам, поддерживаемым разными инструментами. В проекте были подготовлены вспомогательные скрипты преобразования между ASE/extxyz, MLIP `.cfg` и JSON-представлением MLIP-4. При конвертации сохранялись атомные типы, координаты, ячейки, энергии и силы, поскольку эти величины используются при обучении и последующей оценке моделей. Эти скрипты сохранены в provenance-зоне clean hero как часть истории экспериментов; они не являются основной исполняемой точкой репозитория, но фиксируют, как обеспечивалась совместимость данных между MTP, MACE и MatterSim.

4.3. Процедуры обучения и оценки

Здесь будет описано, как были получены сравнимые результаты для моделей, без добавления неподтвержденных оценок стоимости вычислений.

5. Результаты и обсуждение

В этом разделе будут представлены таблицы, графики и обсуждение результатов по каждой системе. Сейчас численные значения намеренно не добавлены.

5.1. Organic

Здесь будет обсуждение результатов для organic-системы.

5.2. H₂O

Здесь будет обсуждение результатов для H₂O.

5.3. MoNbTaVW

Здесь будет обсуждение результатов для MoNbTaVW.

5.4. Сводное обсуждение

Здесь будет аккуратное сопоставление моделей без чрезмерных обобщений.

6. Ограничения исследования

В этом разделе будут описаны ограничения данных, протокола и интерпретации результатов.

Здесь также будут зафиксированы границы утверждений, которые нельзя расширять без дополнительных экспериментов.

7. Заключение

В этом разделе будут кратко подведены итоги исследования и указаны направления дальнейшей работы.

Формулировки заключения должны быть производными от уже проверенных результатов.

Список литературы

- [1] Chi Chen and Shyue Ping Ong. A universal graph deep learning interatomic potential for the periodic table. *Nature Computational Science*, 2:718--728, 2022.
- [2] Ilyes Batatia, Dávid Péter Kovács, Gregor N. C. Simm, Christoph Ortner, and Gábor Csányi. MACE: Higher order equivariant message passing neural networks for fast and accurate force fields. In *Advances in Neural Information Processing Systems*, 2022. TODO: verify final NeurIPS citation format before submission.
- [3] Alexander V. Shapeev. Moment tensor potentials: A class of systematically improvable interatomic potentials. *Multiscale Modeling & Simulation*, 14(3):1153--1173, 2016. TODO: use when describing the MTP baseline.
- [4] Alexander Shapeev, Max Hodapp, Evgeny Podryabinkin, David Demuriia, Dmitry Korogod, and Olga Chalykh. MLIP-4: Machine learning interatomic potentials software package. <https://gitlab.com/ashapeev/mlip-4>, 2024. Software repository; TODO: specify the version or commit used in experiments.
- [5] Han Yang, Chenxi Hu, Yichi Zhou, Xixian Liu, Yu Shi, Jielan Li, Guanzhi Li, Zekun Chen, Shuizhou Chen, Claudio Zeni, Matthew Horton, Robert Pinsler, Andrew Fowler, Daniel Zügner, Tian Xie, Jake Smith, Lixin Sun, Qian Wang, Lingyu Kong, Chang Liu, Hongxia Hao, and Ziheng Lu. MatterSim: A deep learning atomistic model across elements, temperatures and pressures. *arXiv preprint arXiv:2405.04967*, 2024. TODO: verify final publication status before submission.
- [6] MACE developers. MACE documentation: Fine-tuning. <https://mace-docs.readthedocs.io/en/latest/guide/finetuning.html>, 2026. Accessed 2026-05-29; TODO: pin documentation version before final build.
- [7] Microsoft. MatterSim readme: Fine-tuning mattersim models. <https://github.com/microsoft/mattersim>, 2026. Accessed 2026-05-29; TODO: specify commit or release before final build.
- [8] Evgeny Podryabinkin, Kamil Garifullin, Alexander Shapeev, and Ivan Novikov. MLIP-3: Active learning on atomic environments with moment tensor potentials. *arXiv preprint arXiv:2304.13144*, 2023. Software-method paper for the MLIP package line; not an exact description of MLIP-4.

А. Приложения

В приложениях будут размещены материалы, которые важны для воспроизводимости, но перегружают основной текст.

А.1. Дополнительные таблицы

Здесь будет место для расширенных таблиц и проверочных материалов.